



# **Implementierung eines neuronalen Netzwerkes zur Zeichenerkennung in SetIX**

## **Studienarbeit**

Studiengang Angewandte Informatik

Duale Hochschule Baden-Württemberg Mannheim

von

Lucas Heuser und Johannes Hill

Bearbeitungszeitraum:	05.09.2016 - 29.05.2017
Matrikelnummer, Kurs:	-, TINF14AI-BI
Matrikelnummer, Kurs:	-, TINF14AI-BI
Ausbildungsfirma:	Roche Diagnostics GmbH, Mannheim
Abteilung:	Scientific Information Services
Betreuer der DHBW-Mannheim:	Prof. Dr. Karl Stroetmann

---

UNTERSCHRIFT DES BETREUERS

# Eidesstattliche Erklärung

Hiermit erklären wir, dass wir die vorliegende Arbeit mit dem Thema

*Implementierung eines neuronalen Netzwerkes zur Zeichenerkennung in SetIX*

selbstständig und ohne Benutzung anderer als der angegebenen Quellen und Hilfsmittel angefertigt habe.

Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten und nicht veröffentlichten Schriften entnommen wurden, sind als solche kenntlich gemacht.

Die Arbeit ist in gleicher oder ähnlicher Form oder auszugsweise im Rahmen einer anderen Prüfung noch nicht vorgelegt worden.

Mannheim, den 10. April 2017

---

LUCAS HEUSER

---

JOHANNES HILL

# Inhaltsverzeichnis

<b>1</b>	<b>Einleitung</b>	<b>1</b>
1.1	Studienarbeit and DHWB	1
1.2	GitHub Link	1
1.3	Was ist künstliche Intelligenz	1
1.4	Aktuelle Relevanz/Themen von neuronalen Netzen	1
1.5	Ziel der Arbeit	1
1.6	Aufbau der Arbeit	1
<b>2</b>	<b>Theorie</b>	<b>2</b>
2.1	SetlX	2
2.2	MNIST	2
2.3	Neuronales Netzwerk	2
2.4	Perceptrons	3
2.5	Sigmoid Neurons	4
2.6	Netzwerk zur Klassifizierung von handgeschriebenen Zahlen	7
<b>3</b>	<b>Implementierung</b>	<b>8</b>
3.1	Laden und Aufbereitung der MNIST Daten	8
3.2	Implementierung des neuronalen Netzes	8
3.3	Animation	12

# Abbildungsverzeichnis

2.1	Aufbau des neuronalen Netzwerks hinsichtlich der einzelnen Layer. . . . .	2
2.2	Percetron mit den Eingaben $x_1, x_2, x_3$ und der Ausgabe output. . . . .	3
2.3	Unterschiedliche Möglichkeiten der Entscheidungsfindung. . . . .	4
2.4	Sigmoid Funktion $\sigma(z)$ . . . . .	5
2.5	Modifizieren von Weights und Biases schaffen lernendes Netzwerk. . . . .	5
2.6	Sigmoid Funktion $\sigma(z)$ . . . . .	6
2.7	Sigmoid Funktion $\sigma(z)$ . . . . .	6

# Kapitel 1

## Einleitung

### 1.1 Studienarbeit and DHWB

### 1.2 GitHub Link

### 1.3 Was ist künstliche Intelligenz

### 1.4 Aktuelle Relevanz/Themen von neuronalen Netzen

### 1.5 Ziel der Arbeit

Die menschliche Wahrnehmung ist

### 1.6 Aufbau der Arbeit

# Kapitel 2

## Theorie

### 2.1 SetIX

### 2.2 MNIST

### 2.3 Neuronales Netzwerk

In diesem Abschnitt der Arbeit wird der Aufbau eines neuronalen Netzwerks näher betrachtet und entsprechend auf die Terminologie in diesem Bereich eingegangen.

Neuronale Netzwerke sind den biologischen Neuronen nachempfunden und setzen sich daher aus Vielzahl von Neuronen zusammen. Darüber hinaus ist ein Netzwerk in mehrere Schichten untergliedert (siehe Abb.2.1). So wird die erste Schicht auf der linken Seite auch als *Eingabeschicht* und alle korrespondierenden Eingabeknoten als Eingabeneuron bezeichnet. Die letzte Schicht, die sogenannte *Ausgabeschicht*, beinhaltet dagegen alle *Ausgabeneuronen*. Alle Schichten zwischen der Eingabe und der Ausgabe tragen die Bezeichnung des *Hidden Layer*, wobei ein Netzwerk mehrere dieser Schichten aufweisen kann. In der folgenden Grafik ist ein 4-Layer-Netzwerk abgebildet, das zwei *Hidden Layer* besitzt. Diese mehrschichtigen Netzwerke werden ebenfalls als *Multilayer Perceptrons* oder *MLPs* bezeichnet, obwohl das Netzwerk sich aus Sigmoid-Neuronen zusammensetzt.




Abbildung 2.1: Aufbau des neuronalen Netzwerks hinsichtlich der einzelnen Layer.

Für die Zusammensetzung von Eingabe- und Ausgabeschichten in einem Netzwerk, fällt die Betrachtung

auf die Erkennung einer handgeschrieben "9". Als Eingabewerte dienen dem Netzwerk die Intensitäten der Bildpixel. Liegt ein Graustufenbild der Größe von 64x64 Pixeln vor, leiten sich daraus 4096 Eingabeknoten mit skalierten Intensitätswerten zwischen 0 und 1 ab. Die Ausgabeschicht beinhaltet dagegen nur ein Neuron, um eine entsprechende Klassifizierung der "9" vornehmen zu können.

$\text{output} < 0.5 \rightarrow$  "Eingabebild ist keine 9"

$\text{output} \geq 0.5 \rightarrow$  "Eingabebild ist eine 9"

Im Vergleich hierzu ist der Aufbau der Hidden-Layer nicht durch irgendwelche Regeln ableitbar. Zum Einsatz kommen Heuristiken, die das Verhalten eines Netzwerkes bestimmen, welches ausgehend vom Experiment erwartet und gewünscht wird. Zum Beispiel kann untersucht werden, wie die Lernrate des Netzwerkes sich im Verhältnis zu der Anzahl an Hidden-Layer verhält.

Bisher viel die Betrachtung in dieser Arbeit auf neuronale Netze, bei denen die Ausgabe einer Schicht die Eingabe in der nächsten Schicht darstellte. Solche Netzwerke werden auch *Feedforward Neural Networks* bezeichnet. Hierunter ist das das nicht Auftreten von Schleifen zu verstehen - sprich, Informationen werden im Netzwerk immer von Layer  $n$  zu Layer  $n + 1$  übergeben. Somit kann verhindert werden, dass das Netzwerk in gewissen Fällen bei der Eingabe der Sigmoid-Funktion  $\sigma$  von dessen Ausgabe abhängig ist.

Ebenfalls gibt es Netzwerke bei denen sogenannte *Feedback Loops* möglich sind. In diesem Fall handelt es sich um *Recurrent Neural Networks*. Die Idee hinter diesem Modell ist, dass bestimmte Neuronen über einen definierten Zeitraum aktiv sind bevor sie inaktiv werden. Dies kann andere Neuronen anregen, ebenfalls über einen gewissen Zeitraum aktiv zu sein und eine entsprechende Kettenreaktion auslösen (Kaskade). Schleifen stellen in diesem Modell kein Problem dar, da die Ausgabe eines Neurons erst zu einem späteren Zeitpunkt die Eingabe beeinflusst.

Stellt man diese Arten von neuronalen Netzwerken gegenüber, so lässt sie zum heutigen Zeitpunkt die Aussage treffen, dass Feedback Neural Networks weniger Verbreitung finden. Dies ist begründet in der Leistungsfähigkeit der Lernalgorithmen. Jedoch sollte an dieser Stelle berücksichtigt werden, dass mittels Feedback Neural Networks bestimmte Probleme mit einem geringeren architektonischen Aufwand gelöst werden können. Darüber hinaus bildet der komplexere logische Aufbau eines solchen Netzwerkes, das menschliche Verhalten besser ab.

## 2.4 Perceptrons

Ein Perceptron ist ein mathematisches Modell zur Abbildung eines künstlichen Neurons in einem Netzwerk. Es wird für die Entscheidungsfindung herangezogen, indem verschiedene Aussagen abgewägt werden. Hierbei nimmt das Perceptron eine Menge von Eingaben  $x_n$  mit  $n \in \{1, \dots, m\}$  und berechnet einen einzigen binären Ausgabewert (siehe Abb. 2.2).




Abbildung 2.2: Perceptron mit den Eingaben  $x_1, x_2, x_3$  und der Ausgabe output.

Für jeden Eingabewert  $x_n$  wird eine Gewichtung  $w_n$  mit  $n \in \{1, \dots, m\}$  zugeordnet. Der Ausgabewert output wird mittels der gewichteten Summe  $\sum_j w_j x_k$  und einem definierten Grenzwert threshold

bestimmt.

$$\text{output} := \begin{cases} 0 & \text{falls } \sum_j w_j x_j \leq \text{threshold} \\ 1 & \text{falls } \sum_j w_j x_j > \text{threshold} \end{cases} \quad (2.1)$$

Der Aufbau des Netzwerks leitet sich aus den unterschiedlichen Modellen der Entscheidungsfindung ab und wird mit Hilfe der Perceptrons abgebildet (siehe Abb. 2.3). Eine Entscheidungsmöglichkeit wird




Abbildung 2.3: Unterschiedliche Möglichkeiten der Entscheidungsfindung.

hierbei durch das Perceptron dargestellt. Weiterhin wird eine Spalte von Perceptrons als *Layer* bezeichnet. Der erste Layer fällt Entscheidungen auf Basis der Eingabewerte, indem er diese abwägt. Jedes Perceptron des zweiten Layers hingegen, wägt für die Entscheidungsfindung die Resultate des ersten Layers ab. Ein Perceptron auf dem zweiten Layer kann somit eine Entscheidung auf einer abstrakteren und komplexeren Ebene durchführen. Auf diese Weise kann sich ein vielschichtiges Netzwerk von Perceptrons in ein anspruchsvolles Modell zur Entscheidungsfindung entwickeln.

Im folgenden wird die mathematische Beschreibung von Perceptrons vereinfacht, indem Änderungen an der Notation für  $\sum_j w_j x_j > \text{threshold}$  vorgenommen werden. Für die Beschreibung der Summe  $\sum_j w_j x_j$  werden die Vektoren  $\mathbf{w}$  und  $\mathbf{x}$  eingeführt, wodurch sich die Schreibweise  $\mathbf{w} \cdot \mathbf{x} \equiv \sum_j w_j x_j$  ergibt. Des Weiteren wird der *threshold* auf die andere Seite der Ungleichung gezogen und erhält die Bezeichnung *Bias*,  $b \equiv -\text{threshold}$ .

$$\text{output} := \begin{cases} 0 & \text{falls } \mathbf{w} \cdot \mathbf{x} + b \leq 0 \\ 1 & \text{falls } \mathbf{w} \cdot \mathbf{x} + b > 0 \end{cases} \quad (2.2)$$

Dieses mathematische Verhalten wird durch die folgende Stufenfunktion verdeutlicht (Abb. 2.7).

## 2.5 Sigmoid Neurons

Für die Entwicklung lernender Algorithmen in einem Netzwerk mit Perceptrons, fällt unsere Betrachtung auf das Beispiel der Erkennung von handgeschriebenen Zahlen. Die Eingabe für das Netzwerk könnten die Raw Pixeldaten der eingescannten Bilder darstellen, welche die handgeschriebenen Zahlen abbilden. Das Ziel an dieser Stelle ist, dass das Netzwerk anhand der Veränderungen von *Weights* und *Biases* lernt eine korrekte Klassifizierung der Zahlen vorzunehmen.

Das Modifizieren der *Weights* und *Biases* kann das Verhalten des Netzwerkes und deren Entscheidungsfindung zu Problemen beeinflussen. Angenommen die Erkennung und Klassifizierung einer Zahl wurde durch das Netzwerk falsch vorgenommen, so können durch kleine Veränderungen an den *Weights* und *Biases* eine Korrektur durchgeführt werden. Dieses stetige Modifizieren der Werte über einen definierten Zeitraum ermöglicht ein lernendes Netzwerk (siehe Abb. 2.5).





Abbildung 2.4: Sigmoid Funktion  $\sigma(z)$ .

Abbildung 2.5: Modifizieren von Weights und Biases schaffen lernendes Netzwerk.

Dieses wünschenswerte Verhalten eines lernenden Netzwerks kann durch Perceptrons nicht gewährleistet werden, da eine Veränderung der Weights und Biases den Ausgabewerte output eines Neurons umkehren kann. Dadurch kann das komplette Verhalten zur Klassifizierung von Zahlen beeinflusst werden, wobei zuvor falsch erkannte Zahlen nun richtig klassifiziert werden und umgekehrt. Mit Hilfe der Einführung des Sigmoid Neurons soll dieser Fehler behoben werden. Eine Änderung der Weights und Biases bei diesem künstlichen Neuron soll nur marginale Änderungen an dem Ausgabewert output vornehmen. Diese Erweiterung des Neurons begünstigt ein Netzwerk selbständig die Klassifizierung von Zahlen zu optimieren.

Der Aufbau des Sigmoid Neurons ähnelt dem Perceptron, wobei das Neuron eine Anzahl von Eingabewerten  $x_n$  mit  $n \in \{1, \dots, m\}$  entgegennimmt und ausgehend von diesen Informationen den output ermittelt. Der wesentliche Unterschied zwischen diesen zwei Typen von Neuronen liegt in dem Wertebereich des output. Bei dem Sigmoid Neuron kann dieser alle Werte zwischen 0 und 1 annehmen, sprich  $\text{output} \in [0..1]$ . Weiterhin weist auch diese Art von Neuronen für jeden Eingabewert eine Gewichtung  $w_n$  mit  $n \in \{1..n\}$  sowie einen Bias auf.

Für die Berechnung des output wird in diesem Kontext die *Sigmoid Funktion*  $\sigma(z)$  angewendet.

$$\sigma(z) \equiv \frac{1}{1 + e^{-z}} \quad \text{mit} \quad z = w \cdot x + b \quad (2.3)$$

Unter Berücksichtigung der Eingabewerte  $x_n$  mit  $n \in \{1..n\}$  und der Weights  $w_n$  mit  $n \in \{1..n\}$

ergibt sich die folgende Formel:

$$\sigma(z) \equiv \frac{1}{1 + \exp(-\sum_j w_j x_j - b)} \quad (2.4)$$

Dabei weist das Sigmoid Neuron weiterhin das gleiche Verhalten wie ein Perceptron auf, wenn eine Grenzwertbetrachtung durchführt wird.

$$\begin{aligned} \lim_{z \rightarrow \infty} \sigma(z) &\approx 1 && \text{bzw.} \\ \lim_{z \rightarrow -\infty} \sigma(z) &\approx 0 \end{aligned}$$

Dieses Verhalten wird weiterhin verdeutlicht, wenn die Betrachtung auf den folgenden Funktionsgraph fällt (siehe Abb. 2.6). Für große  $z$  nimmt die Funktion den Wert 1 an und für kleine  $z$  nimmt die Funktion den Wert 0 an.




Abbildung 2.6: Sigmoid Funktion  $\sigma(z)$ .

Im Vergleich hierzu die Stufenfunktion, die das Verhalten eines Perceptrons abbildet (siehe Abb. 2.7). Die Vorteile der Sigmoid Funktion liegen in den marginalen Änderungen  $\delta w_j$  bei den Gewichtungen




Abbildung 2.7: Sigmoid Funktion  $\sigma(z)$ .

und  $\delta b$  im Bias, welche eine marginale Änderung am  $\delta \text{output}$  vornehmen. Damit stellt  $\delta \text{output}$  die lineare Funktion bezüglich der Änderungen  $\delta w_j$  und  $\delta b$  in den Weights und Bias dar.

$$\Delta \text{output} \equiv \sum_j \frac{\partial \text{output}}{\partial w_j} \Delta w_j + \frac{\partial \text{output}}{\partial b} \Delta b_j \quad (2.5)$$

Diese Linearität begünstigt die Wahl von kleinen Änderungen in den Weights und Biases, um das Verhalten für ein lernendes Netzwerk abzuleiten.

## **2.6 Netzwerk zur Klassifizierung von handschriebenen Zahlen**

# Kapitel 3

## Implementierung

### 3.1 Laden und Aufbereitung der MNIST Daten

### 3.2 Implementierung des neuronalen Netzes

Dieser Abschnitt beschreibt die eigentliche Implementierung des neuronalen Netzwerkes zur Erkennung von handgeschriebenen Ziffern in SetlX. Um den Code möglichst kompakt zu halten, wurden die in den Originaldateien enthaltenen Kommentarzeilen in dieser Seminararbeit zum größten Teil entfernt. Bei der Umsetzung des Netzwerkes in SetlX wird der SGD-Algorithmus als Lernmethode des Netzwerkes benutzt. Die im vorherigen Kapitel importierten Daten des MNIST-Datensatzes dienen als Grundlage der Ziffernerkennung. Das Netzwerk wird als Klasse in SetlX angelegt und enthält die folgenden Membervariablen:

1. `mNumLayers`: Anzahl der Layer des aufzubauenden Netzwerkes
2. `mSizes`: Aufbau des Layers in Listenform. Bsp.: `[784, 30, 10]` beschreibt ein Netzwerk mit 784 Inputfeldern, 30 Neuronen im zweiten (hidden) Layer und 10 Output-Neuronen
3. `mBiases`: Alle Vorbelastungen des Netzwerkes (genauer Aufbau wird im Folgenden erläutert)
4. `mWeights`: Alle Gewichte des Netzwerkes (genauer Aufbau wird im Folgenden erläutert)

Die Initialisierung des Netzwerkes zur Ziffernerkennung erfolgt durch folgende Befehle:

---

```
1 net := network([784, 30, 10]);
2 net.init();
```

---

Als Übergabeparameter bei der Erstellung eines Netzwerk-Objektes wird die Struktur des Netzwerkes in Form einer Liste übergeben. Diese wird dann lediglich `mSizes` zugeordnet und basierend hierrauf wird `mNumLayers` ermittelt. Die `init()`-Funktion der `network`-Klasse wird verwendet um die Gewichte und Vorbelastungen des Netzwerkes initial zufällig zu belegen. Hiermit werden Ausgangswerte gesetzt, welche später durch das Lernen des Netzwerkes angepasst werden. Im Folgenden sind die verwendeten Funktionen, welche während der Gewichts- und Vorbelastungs-Initialisierung verwendet werden, zu sehen.

---

```
1 init := procedure() {
2     computeRndBiases();
3     computeRndWeights();
```

---

```

4   };
5   computeRndBiases := procedure() {
6       this.mBiases := [
7           computeRndMatrix([1, mSizes[i]]) : i in [2..mNumLayers]
8       ];
9   };
10  computeRndWeights := procedure() {
11      this.mWeights := [
12          computeRndMatrix([mSizes[i], mSizes[i+1]]) : i in [1..mNumLayers-1]
13      ];
14  };
15  computeRndMatrix := procedure(s) {
16      [i,j] := s;
17      return la_matrix([
18          [ ((random()-0.5)*2)/28 : p in [1..i] ] : q in [1..j]
19      ]);
20  };

```

1. `init()`: in der `init`-Funktion werden die Funktionen `computeRndBiases()` und `computeRndWeights()` aufgerufen

2. `computeRndBiases()`: Die Funktion befüllt die Variable `mBiases` mit zufälligen Werten. Der für das Netzwerk benötigte Aufbau der Vorbelastungen entspricht folgender Form:

```

[
<< << b_layer1_neu1 >> << b_layer1_neu2 >> ... >>,
<< << b_layer2_neu1 >> ... >>,
... ]

```

Das heißt es kann auf die Vorbelastungen mit folgendem Schema in SetIX zugegriffen werden:

$$\text{mBiases}[\text{layer}][\text{neuron}][\text{bias}]$$

Hierbei ist zu beachten, dass der Wert für `bias` immer 1 ist, da jedes Neuron nur eine einzige Vorbelastung besitzt. Da es sich bei der Eingabe-Schicht des Netzwerkes nicht um Sigmoid-Neuronen handelt, sondern lediglich um Eingabewerte, werden hierfür keine Vorbelastungen benötigt. Deshalb wird bei der Erstellung der zufälligen Vorbelastungen nur `[2..mNumLayers]` (also alle Schichten außer dem Ersten) betrachtet.

3. `computeRndWeights()`: Diese Funktion ist equivalent zu der Vorbelastungs-Funktion, lediglich wird folgende Struktur der Gewichte angelegt:

```

[
<< << w1_layer2_neu1 w1_layer2_neu2 ... >> << w2_layer2_neu1 ... >> ... >>,
<< << w1_layer3_neu1 w1_layer3_neu2 ... >> << w2_layer3_neu1 ... >> ... >>,
... ]

```

Dies entspricht folgenden Zugriffsmöglichkeiten:

$$\text{mWeights}[\text{layer} - 1][\text{neuron}][\text{weight for input neuron}]$$

Der Zugriff auf die Schichten mittels `[layer - 1]` resultiert aus den fehlenden Gewichten der Eingabe-Schicht.

4. `computeRndMatrix()`: Diese Hilfsfunktion dient zur Erstellung der Struktur der Gewichte und Vorbelastungen in den zuvor vorgestellten Funktionen. Die Funktion enthält als Parameter eine

Matrix-Struktur in Listenform und liefert die zugehörige Matrix mit zufälligen Werten zwischen  $-1/28$  und  $1/28$  zurück. Der Wert 28 ergibt sich aus der Größe des Eingabevektors (28x28 Pixel). Die übergebende Struktur hat die Form  $[x, y]$ , wobei  $x$  die Anzahl der Spalten und  $y$  die Anzahl der Reihen angibt.

Bsp.:  $s := [1, 2] \rightarrow \langle\langle x \rangle\rangle \langle\langle y \rangle\rangle \rangle\rangle$  und  $s := [2, 1] \rightarrow \langle\langle x y \rangle\rangle \rangle\rangle$

Sei nun  $w$  die Matrix der Gewichte und  $b$  die Matrix aller Vorbelastungen und  $a$  bezeichnet den Aktivierungsvektor der vorherigen Schicht, also deren Ausgabe (zu Beginn also die Pixel der Eingabe). Nach Gleichung xyz zur Berechnung einer Sigmoid-Ausgabe lässt sich nun folgende Formel aufstellen:

$$a' = \sigma(wa + b) \quad (3.1)$$

Hierbei bezeichnet  $a'$  den Ausgabe-Vektor der aktuellen Schicht, welcher dann der nächsten Schicht weitergeleitet wird (feedforward). Nachfolgend sind die Implementierungen der Sigmoid-Funktionen sowie dem Feedforwarding zu sehen.

---

```

1  feedforward := procedure(a) {
2      a := la_vector(a);
3      for( i in {1..#mBiases} ) {
4          a := sigmoid( (mWeights[i]*a) + mBiases[i] );
5      }
6      return a;
7  };
8  sigmoid := procedure(z) {
9      return la_vector([ 1.0/(1.0 + exp(- z[i] )) : i in [1..#z] ]);
10 };
11 sigmoid_prime := procedure(z) {
12     s := sigmoid(z);
13     return la_matrix([ [ s[i] * (1 - s[i]) ] : i in [1..#s] ]);
14 };

```

---

1. **feedforward(a)**: Zunächst werden die als Liste übergebenen Eingabewerte  $a$  (784 Pixel in Listenform) mit Hilfe von `la_vektor()` in einen Vektor umgewandelt und anschließend wird die Gleichung (3.1) auf alle Schichten des Netzwerkes angewandt. Zurückgegeben wird die resultierende Ausgabe jedes Neurons der letzten Schicht in vektorisierter Form.
2. **sigmoid(z)**: Diese Funktionen nimmt einen Vektor  $z$  und berechnet mit Hilfe der Sigmoid-Formel (siehe Formel xyz) die Ausgabe der Neuronen in vektorisierter Form.
3. **sigmoid\_prime(z)**: Für einen gegebenen Vektor  $z$  wird die Ableitung der Sigmoid-Funktion (nach Formel xyz) berechnet und in vektorisierter Form zurückgegeben.

Die Feedforward-Funktion dient also dazu, die Eingabewerte durch das gesamte Netzwerk durchzureichen und die daraus resultierende Ausgabe zu ermitteln. Als nächstes wird der Algorithmus diskutiert, durch welchem es dem Netzwerk ermöglicht wird zu „lernen“. Hierfür wird der Stochastic Gradient Descent (SGD) Algorithmus verwendet. Die Implementierung des SGDs in SetIX ist nachfolgend aufgezeigt und wird nun im Detail erläutert.

---

```

1  sgd := procedure(training_data, epochs, mini_batch_size, eta, test_data) {
2      if(test_data != null) {
3          n_test := #test_data;
4      }
5      n := #training_data;

```

---

```

6
7     for(j in {0..epochs}) {
8         training_data := shuffle(training_data);
9         mini_batches := [
10             training_data[k..k+mini_batch_size-1] : k in [1,mini_batch_size..n]
11         ];
12
13         for(mini_batch in mini_batches) {
14             update_mini_batch(mini_batch, eta);
15         }
16
17         if(test_data != null) {
18             ev := evaluate(test_data);
19             print("Epoch $j$: $ev$ / $n_test$");
20         }
21         else {
22             print("Epoch $j$ complete");
23         }
24     }
25 };

```

1. Zeile 1: Übergabeparameter der Funktion sind die Trainingsdatensätze (Liste von Tupeln  $[x, y]$  mit  $x$  als Eingabewerten und  $y$  als gewünschtem Ergebnis), die Anzahl der Epochen (Integer-Wert), die Größe der Mini-Batches (Integer-Wert), die gewünschte Lernrate (Fließkomma-Wert) und den optionalen Testdatensätzen (äquivalenter Aufbau zu Trainingsdaten).
2. Zeile 2-5: Falls Testdaten vorhanden sind, so wird deren Anzahl (Anzahl Datensätze) in der Variablen `n_test` gespeichert. Ebenso wird die Anzahl der Trainings-Datensätze in `n` gesichert.
3. Zeile 7: Nun wird der nachfolgende Programmcode entsprechend der übergebenen Epochenanzahl mehrfach ausgeführt.
4. Zeile 8-12: Zuerst werden alle Trainingsdaten zufällig vermischt und anschließend Mini-Batches (also Ausschnitte aus dem Gesamtdatensatz) der vorher festgelegten Größe aus den Trainingsdaten extrahiert. Somit wird eine zufällige Belegung von Mini-Batches garantiert. Alle Mini-Batches werden in Listenform in der Variablen `mini_batches` gespeichert.
5. Zeile 14-16: Anschließend wird für jeden Mini-Batch aus `mini_batches` ein Schritt des SGD angewendet. Dies geschieht mit Hilfe der Funktion `update_mini_batches`, welche anschließend genauer erläutert wird. Zweck der Funktion ist es die Gewichte und Vorbelastungen des Netzwerkes mit Hilfe einer Iteration des SGD-Algorithmus anzupassen. Die Basis für diese Anpassung liefert der übergebene Mini-Batch und die Lernrate.
6. Zeile 19-25: Dieser Programmcode dient zur Ausgabe auf der Konsole und teilt dem Benutzer die aktuelle Anzahl an korrekt ermittelten Datensätzen der Trainingsdaten nach jeder Epoche mit. Hierfür wird die Hilfsfunktion `evaluate` verwendet, welche unter Berücksichtigung des aktuellen Netzwerkzustandes die Outputs ermittelt, welcher bei Eingabe der Testdaten durch das Netzwerk errechnet wurden (genaue Implementierung folgt). Sollten der `sgd`-Funktion keine Testdaten übergeben worden sein, so entfällt diese Ausgabe.

ToDo: evaluate und update-mini-batch

Eine vorgefertigte Prozedur zur Initialisierung des benötigten Netzwerkes mit Beispielparametern befindet sich in der Datei `start.stlx`, welche mit dem Befehl `setlx start.stlx` über die Konsole gestartet werden kann.

## 3.3 Animation